

למידה סטטיסטית מבוססת נתונים - חורף - 096411

## **HW2**

**מגישים:**

**איתי ברקוביץ 039632732**

**אילן פרנק 043493386**

תוצאה

טענה

$$B = \|W^*\|, R = \max \|x_i\|, W^* = \arg \min \{ \|W\| : \forall i, y_i \langle W, x_i \rangle \geq 1 \}$$

$$\langle W^*, W^{(T+1)} \rangle \geq T \quad \text{כל וקטור ב-} T \text{ איטרציות (קבץ)}$$

הוכחה:

$$W^{(1)} = (0 \dots 0) \quad \text{ו-} W^{(1)} \text{ איננו בהיסקה} \\ \langle W^*, W^{(1)} \rangle = 0 \quad \text{כלומר בהיסקה}$$

$$\begin{aligned} \langle W^*, W^{(f+1)} \rangle - \langle W^*, W^{(f)} \rangle &= \langle W^*, W^{(f+1)} - W^{(f)} \rangle \\ &= \langle W^*, y_f x_f \rangle = y_f \langle W^*, x_f \rangle \\ &\geq 1 \end{aligned}$$

$$\langle W^*, W^{(T+1)} \rangle = \sum_{f=1}^T (\langle W^*, W^{(f+1)} \rangle - \langle W^*, W^{(f)} \rangle) = \sum_{f=1}^T \geq 1 \geq T$$

$$\Rightarrow \langle W^*, W^{(T+1)} \rangle \geq T$$

$$\|W^{(T+1)}\|^2 \leq T R^2 \quad \text{כל וקטור ב-} T \text{ איטרציות מקבל}$$

$$\begin{aligned} \|W^{(f+1)}\|^2 &= \|W^{(f)} + y_f x_f\|^2 \\ &= \|W^{(f)}\|^2 + 2 y_f \langle W^{(f)}, x_f \rangle + y_f^2 \|x_f\|^2 \\ &\leq \|W^{(f)}\|^2 + R^2 \end{aligned}$$

האי שוויון האחרון מתקבל מכיוון שאם  $y_f x_f$  הוא וקטור, אז  $\langle W^{(f)}, x_f \rangle \geq 1$  (בהיסקה).

מכיוון ש- $\langle W^*, x_f \rangle \geq 1$  ו- $\|x_f\| \leq R$ , אז  $\langle W^*, W^{(f+1)} \rangle \geq \langle W^*, W^{(f)} \rangle + 1$  (קבץ).

$$\|W^{(f+1)}\|^2 \leq T R^2$$

ד. נראה שסדר מידע  $T$  יורשני  $(\geq)$ :

$$1 \geq \frac{\langle w^*, w^{(t+1)} \rangle}{\|w^*\| \|w^{(t+1)}\|} \geq \frac{\sqrt{T}}{\sqrt{B}}$$

• הבה  $\frac{\sqrt{T}}{\sqrt{B}}$  מידע יותר גדול מן וקטור  $w^*$  וקטור  $w^{(t+1)}$

לכן לפי המצב  $\cos(\alpha) \leq 1$  נכון

$$1 \geq \frac{\sqrt{T}}{\sqrt{B}}$$

• מסתקף:

$$\|w^{(t+1)}\|^2 \leq T R^2 \Rightarrow \|w^{(T+1)}\| \leq \sqrt{T} R$$

• נראה כי המסלול מסתיים חצי יורשני  $\|w^*\| = \sqrt{B}$  (גבול)

$$1 \geq \frac{\langle w^{(T+1)}, w^* \rangle}{\|w^*\| \|w^{(T+1)}\|} \geq \frac{T}{\sqrt{B} \sqrt{T} R} = \frac{\sqrt{T}}{\sqrt{B} R}$$

3. מסתקף כי ניתן להאריך:

$$1 \geq \frac{\sqrt{T}}{\sqrt{B} R} \rightarrow (\sqrt{B} R)^2 \geq T$$

לכן ממספר התבוננות אחד מספר איטרציות מסוים.

In [6]:


```

#2 שאלה
from utils import load_mnist
from sklearn.model_selection import train_test_split

import numpy as np
import matplotlib.pyplot as plt

# סעיף ב
def func(x):
    x = np.array(x)
    y = eval('3+3*x+3*x**2')
    plt.plot(x, y)
    plt.show()
    pass
x = range(-100, 100)
func(x)

```



In [7]:

```

# סעיף ב
def grad(x):
    return 3+6*x

```

In [8]:

```

# נקודת הקיצון של הפונקציה
x_min = -0.5

```

In [9]:

```

# סעיף ד
def updt(grad, x, a):
    return x - a*grad(x)

```

In [10]:

```
#סעיף 7
t = 0.01
a = 0.1
i = 1
curr_x = x[0]
next_x = updt(grad, curr_x , a)

while abs(next_x-curr_x) > t:
    curr_x = next_x
    next_x = updt(grad, curr_x , a)

print(next_x)
print(f'The value is different because of the convergence condition t={t}.')
print('As t goes to 0, the value we get will be closer to -0.5.')
```

-0.50417333248

The value is different because of the convergence condition t=0.01.

As t goes to 0, the value we get will be closer to -0.5.

In [14]:

```
#question 3:

#download data:
import requests
import pandas as pd

from sklearn.datasets import fetch_mldata

def load_mnist():
    try:
        mnist = fetch_mldata('MNIST original')

        data_df = pd.DataFrame(mnist['data'])
        label_df = pd.DataFrame(mnist['target'])

        return data_df, label_df
    except requests.exceptions.RequestException:
        print('HTTP exception, check you connection and try again')

data_df , label_df = load_mnist()
```

In [15]:

```
import numpy as np
data_df = np.array(data_df)
label_df = np.array(label_df)
```

In [16]:

```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(data_df, label_df, test_size=0.25,
random_state=1000)
```

In [18]:

```
#ירמול הערכים
from sklearn.preprocessing import MinMaxScaler
scaler = MinMaxScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

C:\Users\lenovo\Anaconda3\lib\site-packages\sklearn\utils\validation.py:47  
 5: DataConversionWarning: Data with input dtype uint8 was converted to float64 by MinMaxScaler.  
 warnings.warn(msg, DataConversionWarning)

In [19]:

```
#סעיף א: התאמת מודל
from sklearn.svm import SVC # "Support vector classifier"
model = SVC(kernel='linear')
model.fit(X_train, y_train.ravel())
```

Out[19]:

```
SVC(C=1.0, cache_size=200, class_weight=None, coef0=0.0,  

    decision_function_shape='ovr', degree=3, gamma='auto', kernel='linear',  

    max_iter=-1, probability=False, random_state=None, shrinking=True,  

    tol=0.001, verbose=False)
```

In [20]:

```
#סעיף ב
y_pred = model.predict(X_test)

from sklearn.metrics import confusion_matrix

confusion_matrix(y_pred, y_test)
```

Out[20]:

```
array([[416,  1,  2,  0,  1,  4,  5,  0,  3,  1],  

       [ 0, 482, 13,  4,  1,  2,  0,  1,  4,  1],  

       [ 2,  2, 388,  4,  2,  9,  5,  8,  9,  6],  

       [ 2,  3,  5, 386,  1, 20,  1,  3, 10,  2],  

       [ 0,  2,  6,  0, 418,  5,  3,  8,  2, 23],  

       [ 6,  2,  0, 20,  1, 368,  2,  2, 14, 10],  

       [ 5,  0,  6,  0,  3,  6, 395,  0,  3,  0],  

       [ 0,  0,  4,  4,  1,  0,  2, 404,  3, 13],  

       [ 2,  2,  8,  7,  0, 10,  1,  1, 365,  2],  

       [ 0,  0,  2,  4, 13,  1,  0, 13,  5, 389]], dtype=int64)
```

In [21]:

```
from sklearn import metrics
print (metrics.accuracy_score(y_test,y_pred))
```

0.9168

In [23]:

```
model.score(X_test,y_test)
```

Out[23]:

0.9168

In [24]:

```
model.score(X_train,y_train)
```

Out[24]:

1.0

In [17]:

```

#סעיף ג
#changing the degress of the polynomial:

from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import PolynomialFeatures
import matplotlib.pyplot as plt

ind = [0,1,2,3]
degrees= [0,2,8,20]
score_matrix = np.zeros(4)


for i, deg in zip(ind,degrees):
    model = SVC(kernel = 'poly', degree = deg)
    model.fit(X_train, y_train.ravel())
    y_pred = model.predict(X_test)
    score_matrix[i] = metrics.accuracy_score(y_test,y_pred)

plt.figure()
plt.plot(degrees, score_matrix)
plt.xlabel('Degree')
plt.ylabel('Score')

```

Out[17]:

Text(0,0.5, 'Score')








In [24]:

```
#changing the X and gamma parameter for rbf kernel function:
index = [0,1,2]
gamma= [0.001, 1 , 5]
C_parameter = [0.1,1,150]
score_matrix = np.zeros(3)

for this_gamma in gamma[:3]:
    for i, this_C in zip(index,C_parameter):
        model = SVC(kernel = 'rbf', gamma = this_gamma,C = this_C)
        model.fit(X_train, y_train.ravel())
        y_pred = model.predict(X_test)
        score_matrix[i] = metrics.accuracy_score(y_test,y_pred)

plt.figure()
plt.plot(C_parameter, score_matrix)
plt.title('gamma= {}'.format(this_gamma))
plt.xlabel('C')
plt.ylabel('Score')
```



In [26]:

```
model = SVC(kernel = 'rbf', gamma = 0.1, C = 2)
model.fit(X_train, y_train.ravel())
y_pred = model.predict(X_test)
score_matrix = metrics.accuracy_score(y_test, y_pred)
```

סעיף ד:

בחנו מספר סוגי מודלים עם פונקציות kernel שונות:

- עבור kernel פולינומי, בחנו את התנהגות המודל בהתאם לשינוי מעלת הפוליונים. קיבלנו תוצאה של 0.96 עבור ה-score matrix
  - עבור kernel rbf, בחנו את התנהגות המודל כפונקציה של שינוי ערכי C וערכי gamma. עבור כל המקרים, קיבלנו התאמה נמוכה של המודל. הסיבה לכך כנראה נובעת מהאופי הנתונים והפונקציה הנ"ל אינה יודעת לייצר הפרדה טובה בין הקבוצות.
- מסקנה: עם kernel פולינומי ממעלה 2, הצלחנו לשפר את התאמת המודל.

In [11]:

#4 שאלה

```

import datetime
from sklearn.metrics import confusion_matrix
from utils import load_mnist
from sklearn.model_selection import train_test_split
from sklearn.svm import SVC
from sklearn.datasets.samples_generator import make_blobs
import numpy as np
from sklearn.datasets import load_iris

```

```

def ex4(data):
    p_x = data["X"]
    p_y = data["y"]
    input_dim = len(p_x[0])
    w = np.zeros(input_dim)
    max_reps = 1000

    for t in range(max_reps):
        indicator = 1
        for i in range(len(p_x)):
            if np.dot(w, p_x[i])*p_y[i] <= 0:
                w += p_x[i]*p_y[i]
                indicator = 0
            break
        if indicator == 1:
            return (w.transpose(),t)

```

#בדיקת האלגוריתם

```

def test_perceptron():

    data = load_iris()
    p_x = np.array(data.data)
    p_y = np.array(data.target)
    # only the first class is separable
    selected_class = 0
    p_y[p_y != selected_class] = -1
    p_y[p_y == selected_class] = 1
    w,t = ex4({"X": p_x, "y": p_y})
    print(w,t)
test_perceptron()

```

[ 1.3 4.1 -5.2 -2.2] 5