

שאלה 7

$$S = (z_1, \dots, z_m)$$

$$z_i = (x_i, y_i)$$

סט גזירות א' מיון

$$z_i^?$$

גזירות א' מיון

$$S^{(1)} = (z_1, \dots, z_{i-1}, z_i, z_{i+1}, \dots, z_m)$$

גזירות א'

$$U(m) \sim U[1, m]$$

גזירות א'

$$f_S(w) = \frac{1}{m} \sum_{i=1}^m l(w, z_i) + \lambda \|w\|^2$$

גזירות א'

$$\hat{w} = \arg \min f_S(w)$$

$$L_D(\hat{w}) = E_{(z) \sim D} l(\hat{w}, z)$$

גזירות א'

$$L_S(\hat{w}) = \frac{1}{m} \sum_{i=1}^m l(\hat{w}, z_i)$$

$$E_{S \sim D, m} [L_D(\hat{w}) - L_S(\hat{w})] = E_{(S, z') \sim D^{m+1}, m \sim U(m)} [l(\hat{w}^{(1)}, z_i) - l(\hat{w}, z_i)]$$

גזירות א'

* אלוהים יצא נקמה נח שאם נבחר שני גזירות א' מיון, הוא יבחר את שני גזירות א' מיון.

* צ"ח אגודת גזירות א' מיון נבחרת בגזירות א' מיון S-הן שני גזירות א' מיון וקראו אותן S^{(1)} ונבחר את גזירות א' מיון.

הוכחה:

מכיוון ש-S ו-S' שני גזירות א' מיון, אז S ו-S' שני גזירות א' מיון.

$$E_S \{L_D(\hat{w})\} = E_{S, z} [l(\hat{w}, z_i)] = E_{S, z'} [l(\hat{w}^{(1)}, z_i)] \quad (1)$$

נניח אומר ש-

$$E_S \{L_S(\hat{w})\} = E_{S, i} [l(\hat{w}, z_i)] \quad (2)$$

אם S ו-S' שני גזירות א' מיון, אז S ו-S' שני גזירות א' מיון.

$$Y = f(x) + \epsilon, \epsilon \sim N(0, \sigma^2)$$

$$E\{(y - \hat{f}(x))^2\}$$


אנחנו
נחשב
אנחנו

$$\text{Bias}\{\hat{f}(x)\} = E\{\hat{f}(x) - f(x)\}$$


$$\text{Var}\{f(x)\} = E\{\hat{f}(x)^2\} - (E\{\hat{f}(x)\})^2$$

Bias = מידת אהבה של המודל
לשגור או נכסס. Bias גבוה יותר אומר
אנחנו אפסס דברים שיש להם אפסס
או שגור גבוה (underfitting)


Variance = מידת אהבה של המודל
לvariance גבוה אומר אנחנו אהבנו
אם אהבנו את כל הדברים אנחנו אהבנו
variance גבוה יותר (overfitting)
נראה ונראה:



High Bias
low Variance



מודל אהבנו
אנחנו אהבנו



low Bias
High variance

אנחנו נחשב Bias גבוה או נכסס, אנחנו
אנחנו אהבנו את כל הדברים אנחנו אהבנו
אנחנו אהבנו את כל הדברים אנחנו אהבנו
אנחנו אהבנו את כל הדברים אנחנו אהבנו
אנחנו אהבנו את כל הדברים אנחנו אהבנו
אנחנו אהבנו את כל הדברים אנחנו אהבנו

$$E\{(y - \hat{f}(x))^2\} = (\text{Bias}\{\hat{f}(x)\})^2 + \text{Var}\{\hat{f}(x)\} + \sigma^2$$

$$1) E(x^2) = \text{Var}(x) + (E(x))^2$$

$$E(f) = f$$

$$\Rightarrow 2) y = f + \epsilon, \text{ and } E(\epsilon) = 0 \Rightarrow E(y) = E(f + \epsilon) = E(f) + E(\epsilon) = f$$

$$\text{Var}\{\epsilon\} = \sigma^2$$

$$3) \text{Var}(y) = E\{(y - E(y))^2\} = E\{(y - f)^2\} = E\{(f + \epsilon - f)^2\} = E(\epsilon^2)$$

$$(1) \text{Var}(y) = \text{Var}(\epsilon) + (E(\epsilon))^2 = \sigma^2$$

$$\begin{aligned} E\{(y - \hat{f})^2\} &= E\{(f + \epsilon - \hat{f})^2\} = E\{(f + \epsilon - \hat{f} - E(\hat{f}) + E(\hat{f}))^2\} \\ &= E\{(f - E(\hat{f}))^2\} + E(\epsilon^2) + E\{(E(\hat{f}) - \hat{f})^2\} + 2E\{(f - E(\hat{f})) \cdot E(\hat{f})\} \\ &\quad + 2E\{(f - E(\hat{f})) \cdot E(\epsilon)\} + 2E\{(f - E(\hat{f})) \cdot (E(\hat{f}) - \hat{f})\} \\ &\quad + E(\epsilon) \cdot E\{(E(\hat{f}) - \hat{f})\} \end{aligned}$$

$$= E\{(f - E(\hat{f}))^2\} + E(\epsilon^2) + E\{(E(\hat{f}) - \hat{f})^2\}$$

$$= (f - E(\hat{f}))^2 + \sigma^2 + \text{Var}(\hat{f})$$

$$= \text{Bias}(\hat{f}(x))^2 + \sigma^2 + \text{Var}(\hat{f})$$

Q.E.D.

2) א.

הנקודה היחידה שאנחנו רוצים להוכיח היא כי הפונקציה $\text{loss}(z, w)$ היא פונקציה קמורה. כדי להוכיח זאת, נשתמש בנגזרת. נגזור את $\text{loss}(z, w)$ ביחס ל- w . נקבל:

$$\frac{\partial \text{loss}(z, w)}{\partial w} = 1 - y \langle w, x \rangle$$

הנגזרת היא פונקציה קמורה, ולכן $\text{loss}(z, w)$ היא פונקציה קמורה. נשתמש בנגזרת שנייה כדי להוכיח זאת:

$$\frac{\partial^2 \text{loss}(z, w)}{\partial w^2} = -y x x^T$$

הנגזרת השנייה היא מטריצה שלילית, ולכן $\text{loss}(z, w)$ היא פונקציה קמורה.

א. נגדיל את $\text{loss}(z, w)$ כפונקציה של w .

$$\text{loss}(z, w) = \text{loss}(z, u) = 0 \quad (i)$$

$$|\text{loss}(z, w) - \text{loss}(z, u)| = 0 \leq \|z\| \|w - u\| \quad \text{ע"פ (i)}$$

$$\text{loss}(z, w) = 1 - y \langle w, x \rangle, \quad \text{loss}(z, u) = 1 - y \langle u, x \rangle \quad (ii)$$

$$\begin{aligned} |\text{loss}(z, w) - \text{loss}(z, u)| &= |1 - y \langle w, x \rangle - (1 - y \langle u, x \rangle)| \\ &= |y| |\langle w - u, x \rangle| = |y| \|w - u\| \|x\| \leq \|w - u\| \|x\| \end{aligned}$$

(iii) בנ"ב

$$\text{loss}(z, w) = 1 - y \langle w, x \rangle > 0$$

$$\text{loss}(z, u) = 0 < 1 - y \langle u, x \rangle$$

$$\begin{aligned} |\text{loss}(z, w) - \text{loss}(z, u)| &= |1 - y \langle w, x \rangle - 0| = |1 - y \langle w, x \rangle| \\ &= |1 - y \langle w, x \rangle - (1 - y \langle u, x \rangle)| = |y| |\langle w - u, x \rangle| \leq |y| \|w - u\| \|x\| \end{aligned}$$

נראה כי $\text{loss}(z, w)$ היא פונקציה קמורה.

ל. ניתן להוכיח כי $\text{loss}(z, w)$ היא פונקציה קמורה. נשתמש בנגזרת שנייה כדי להוכיח זאת:

$$\frac{\partial^2 \text{loss}(z, w)}{\partial w^2} = -y x x^T$$

הנגזרת השנייה היא מטריצה שלילית, ולכן $\text{loss}(z, w)$ היא פונקציה קמורה.

$$d. \text{ זכור } \log(z, w) = \log(1 + e^{-xw})$$

$$f(t) = \log(1 + e^{-t}) \rightarrow \text{נבדוק}$$

$$\text{מכיון } 0 < e^{-t} \text{ לכל } t \in \mathbb{R}, \text{ אז } f \text{ היא פונקציה קמורה ו-} f''(t) > 0$$

ואז נשתמש במשפט הממוצע (משפט הממוצע) כדי להוכיח:

$$f'(c) = \frac{f(a) - f(b)}{a - b}$$

$$\forall a, b \in \mathbb{R} \\ \text{זכור } c \text{ נמצא} \\ \text{כזה ש-} b < c < a$$

$$f'(t) = \frac{1}{1 + e^{-t}} \cdot (-e^{-t}) = -\frac{e^{-t}}{1 + e^{-t}}$$

כלומר הפונקציה f' היא פונקציה קמורה, ולכן:

$$|f'(b)| < 1 \quad \forall t \in \mathbb{R}$$

$$\text{וכתוצאה } f(a) - f(b) \leq a - b$$

(1-ליפטיות)

$$\text{זכור } \log(z, w) \text{ היא פונקציה קמורה, } x, w \in \mathbb{R}$$

$$g(z, w) = yxw, \text{ כלומר } f \circ g(z, w)$$

$$\text{אכן נראה שהפונקציה } \frac{\partial \log(z, w)}{\partial w} = \frac{\partial f}{\partial t} \frac{\partial g}{\partial w} = yx$$

ובעזרת משפט הממוצע:

$$\log(z, w) - \log(z, u) \leq |w - u| |yx| = |w - u| |x|$$

d. בדיוק זה - אם x הוא מודול "רציף" של x ו- y הוא מודול "רציף" של y אז:


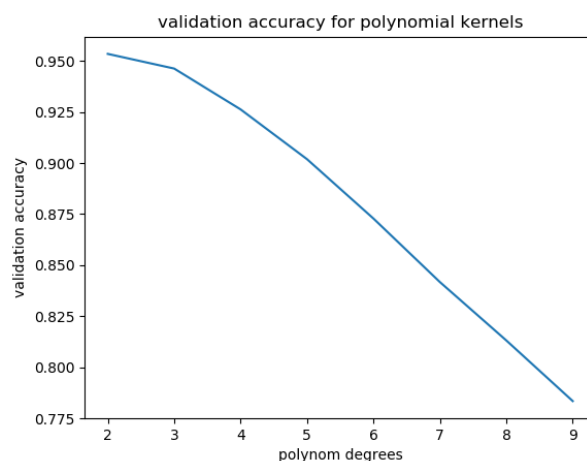
4)

Results:

linear: [1.0, 0.90390625, 0.913125]
poly_2: [1.0, 0.9534374999999999, 0.960625]
poly_3: [1.0, 0.94625, 0.950625]
poly_4: [1.0, 0.9262499999999999, 0.94125]
poly_5: [1.0, 0.9018750000000001, 0.920625]
poly_6: [1.0, 0.8728125, 0.895625]
poly_7: [1.0, 0.8417187500000001, 0.86875]
poly_8: [1.0, 0.813125, 0.845625]
poly_9: [1.0, 0.7834375, 0.8125]
rbf_0.001: [0.9140625, 0.9040625, 0.903125]
rbf_0.01: [0.9776953124999999, 0.9475000000000001, 0.951875]
rbf_0.1: [1.0, 0.83890625, 0.85625]
rbf_1: [1.0, 0.17625000000000002, 0.165625]
rbf_10: [1.0, 0.11046875, 0.105]

the poly_2 model was best on cross validation with error 0.9534374999999999

the poly_2 model was best on test data with error 0.960625



$$\|\hat{w}^{(ii)} - \hat{w}\|^2 \leq \frac{\ell(\hat{w}^{(ii)}, z_i) - \ell(\hat{w}, z_i)}{m} + \frac{\ell(\hat{w}, z_i) - \ell(\hat{w}^{(ii)}, z_i)}{m}$$

מכאן נשתמש בזה כדי להוכיח את הטענה הראשונה.
 נניח שיש לנו מודל \hat{w} ונתון $\hat{w}^{(ii)}$ שהוא המודל הטוב ביותר
 מבין המודלים שנוצרו על ידי \hat{w} ו- z_i . אז יש לנו
 שני מודלים (כאן \hat{w} ו- $\hat{w}^{(ii)}$) ויש לנו את \hat{w} .
 ה- \hat{w} הוא המודל ה- overfit של המודל $\hat{w}^{(ii)}$.

ההוכחה של הטענה השנייה, אבל לא הוכחה:

$$1) \ell(\hat{w}^{(ii)}, z_i) - \ell(\hat{w}, z_i) \leq \rho |\hat{w}^{(ii)} - \hat{w}|$$

הוכחה:

$$2) \ell(\hat{w}, z') - \ell(\hat{w}^{(ii)}, z') \leq \rho |\hat{w}^{(ii)} - \hat{w}|$$

הוכחה: נניח שיש לנו מודל \hat{w} ונתון $\hat{w}^{(ii)}$ שהוא המודל הטוב ביותר
 מבין המודלים שנוצרו על ידי \hat{w} ו- z_i .

$$\|\hat{w}^{(ii)} - \hat{w}\|^2 \leq \frac{\rho |\hat{w}^{(ii)} - \hat{w}|}{m} + \frac{\rho |\hat{w}^{(ii)} - \hat{w}|}{m} = \frac{2\rho |\hat{w}^{(ii)} - \hat{w}|}{m}$$

$$\Rightarrow \|\hat{w}^{(ii)} - \hat{w}\| \leq \frac{2\rho}{m} \Rightarrow \ell(\hat{w}^{(ii)}, z_i) - \ell(\hat{w}, z_i) \leq \frac{2\rho}{m}$$

הוכחה: נניח שיש לנו מודל \hat{w} ונתון $\hat{w}^{(ii)}$ שהוא המודל הטוב ביותר
 מבין המודלים שנוצרו על ידי \hat{w} ו- z_i . אז יש לנו
 שני מודלים (כאן \hat{w} ו- $\hat{w}^{(ii)}$) ויש לנו את \hat{w} .
 ה- \hat{w} הוא המודל ה- overfit של המודל $\hat{w}^{(ii)}$.